



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DEL PERÚ

INTELIGENCIA ARTIFICIAL (INF371)

RESOLUCIÓN DE PROBLEMAS CON BÚSQUEDA: BÚSQUEDA LOCAL

Dr. Edwin Villanueva Talavera

- Algoritmos de búsqueda Local y optimización
 - ▣ Hill-climbing
 - ▣ Simulated annealing
 - ▣ Beam Search

Bibliografía:

Capítulo 4.1 del libro:

Stuart Russell & Peter Norvig “[Artificial Intelligence: A modern Approach](#)”,
Prentice Hall, Third Edition, 2010


Búsqueda local y optimización



- Los algoritmos vistos hasta ahora exploran espacios de búsqueda manteniendo en memoria los caminos explorados, cuando encuentran un estado objetivo, el camino hacia él constituye una solución
- En muchos problemas de optimización el camino hasta el objetivo es irrelevante:
 - ▣ Cuando se quiere encontrar solo una configuración objetivo, sin importar la secuencia de acciones
- En ese caso se puede usar algoritmos de búsqueda local:
 - ▣ No se mantiene un árbol de búsqueda, sólo un nodo con el estado actual
 - ▣ Iterativamente se modifica el estado actual usando información de los estados vecinos

Ejemplo: Problema de las n-reinas

- Colocar n reinas en un tablero $n \times n$, tal que cada fila, columna y diagonal tenga solo una reina:




Características de métodos de búsqueda local:

- Usan muy poca memoria, usualmente una cantidad constante
- A menudo encuentran soluciones razonables en espacios de estados enormes o infinitos (continuos), donde los métodos que exploran caminos no funcionarían
- Pueden ser útiles para resolver problemas de **optimización** puros, donde se necesita encontrar el mejor estado de acuerdo a una **función objetivo**

Superficie de espacio de estados:

- La superficie tiene localización (estado) y elevación (definido por la función objetivo o costo)



Metodo Hill-Climbing



- Usa un solo nodo que mantiene el estado actual y el valor de la función objetivo o función de costo
- Solo examina los valores de los estados vecinos al estado actual
- Continuamente se mueve en la dirección donde se obtiene el mayor incremento si es función objetivo o mayor decremento si es función costo
- Termina cuando se encuentra un pico (o valle) donde ningún estado vecino tiene mas alto (mas bajo) valor

Metodo Hill-Climbing



Pseudocódigo:

```
function HILL-CLIMBING(problem) returns a state that is a local maximum  
current  $\leftarrow$  MAKE-NODE(problem.INITIAL-STATE)  
loop do  
    neighbor  $\leftarrow$  a highest-valued successor of current  
    if neighbor.VALUE  $\leq$  current.VALUE then return current.STATE  
    current  $\leftarrow$  neighbor
```


Limitaciones:

- Puede no encontrar la solución óptima por las siguientes razones:
 - ▣ **Máximos locales:** picos de la superficie del espacio de estados donde ningún estado vecino tiene mayor valor
 - ▣ **Crestas:** secuencias de picos que son muy difíciles de explorar
 - ▣ **Mesetas:** áreas planas del espacio de estados donde hill-climbing se quedaría perdido


Metodo Hill-Climbing

Ejemplo: Problema de las 8 reinas

- Imaginemos el problema de las 8 reinas con función de costo:
 h = número de pares de reinas que se atacan mutuamente
- Sucesores:** todos los posibles estados generados de mover una simple reina de un casillero a otro en la misma columna

18	12	14	13	13	12	14	14
14	16	13	15	12	14	12	16
14	12	18	13	15	12	14	14
15	14	14	♔	13	16	13	16
♔	14	17	15	♔	14	16	16
17	♔	16	18	15	♔	15	♔
18	14	♔	15	15	14	♔	16
14	14	13	17	12	14	12	18

Valores de h de todos los sucesores posibles del estado actual ($h = 17$)



Un posible mínimo local con $h = 1$

Existe una probabilidad de 84% de atracarse en mínimo local!

Posibles mejoras :

- Movimientos laterales para evitar mesetas
 - ▣ Sin embargo puede ocurrir repetición infinita, hay que imponer un limite para el numero de movimientos laterales.
- Stochastic hill-climbing
 - ▣ Escoje aleatoriamente el sucesor con probabilidad proporcional al aumento de la función objetivo
- Reinicios aleatorios (Random-restart Hill-climbing)
 - ▣ Ejecutar varias búsquedas a partir de varios estados iniciales escogidos aleatoriamente.
 - ▣ Es completa, pues en el peor de los casos irá acabar generando el estado objetivo como estado inicial, sin embargo es ineficiente.

Metodo Simulated Annealing

- Combina *hill-climbing* con caminos aleatorios (*random walk*), lo que le garantiza completitud y una mayor eficiencia
- Simula el proceso de templado de metales: al inicio se da una gran temperatura para luego ir la bajando gradualmente:
 - ▣ Gran temperatura significa una alta probabilidad de que estados vecinos con pobre evaluación puedan ser escogidos como sucesores. Esto le permite escapar de óptimos locales.
 - ▣ Esa probabilidad disminuye con el pasar del tiempo

Método Simulated Annealing



Pseudocódigo:

```
function SIMULATED-ANNEALING(problem, schedule) returns a solution state
  inputs: problem, a problem
           schedule, a mapping from time to “temperature”

  current  $\leftarrow$  MAKE-NODE(problem.INITIAL-STATE)
  for  $t = 1$  to  $\infty$  do
     $T \leftarrow$  schedule( $t$ )
    if  $T = 0$  then return current
    next  $\leftarrow$  a randomly selected successor of current
     $\Delta E \leftarrow$  next.VALUE – current.VALUE
    if  $\Delta E > 0$  then current  $\leftarrow$  next
    else current  $\leftarrow$  next only with probability  $e^{\Delta E/T}$ 
```

Método Simulated Annealing

Propiedades:

- Es posible probar que si T decrece lo suficientemente lento, la búsqueda puede encontrar una solución óptima global con probabilidad tendiendo a 1
- *Simulated Annealing* es muy usada en software de diseño de circuitos integrados, optimización de redes de telecomunicaciones, *planificación* de instalaciones industriales, etc.

Metodo Local Beam search



Metodo Local Beam search:

- Mantiene k estados en lugar de uno
- Empieza con k estados generados aleatoriamente
- En cada iteración se generan todos los sucesores de los k estados
- Si alguno de ellos es el estado objetivo entonces la búsqueda termina, de lo contrario se selecciona los k mejores estados de la lista y se continua iterando
- Sufre de falta de diversidad: rápidamente la búsqueda se concentra en una pequeña región del espacio de estados:
 - ▣ Una alternativa es *stochastic beam search*, la cual escoge los k sucesores aleatoriamente con probabilidad proporcional a sus valores



Preguntas?