

INTELIGENCIA ARTIFICIAL (INF371)

*RAZONAMIENTO PROBABILÍSTICO CON REDES
BAYESIANAS (PARTE 2)*

Dr. Edwin Villanueva Talavera

Contenido

- Redes Bayesianas
 - Representación de conocimiento
 - Semántica de Redes Bayesianas
 - Construyendo una Red Bayesiana
 - Inferencia en Redes Bayesianas

Bibliografía:

Capitulo 14.1, 14.2, 14.4 del libro:

Stuart Russell & Peter Norvig “[Artificial Intelligence: A modern Approach](#)”,
Prentice Hall, Third Edition, 2010

Redes Bayesianas

- Modelos para especificar de forma concisa la distribución de probabilidad conjunta de un conjunto de variables aleatorias explotando las relaciones de independencia condicional entre variables
- Especificación de una RB:
 - Un **Grafo Acíclico Direccionado (DAG)** con n nodos representando n variables aleatorias $[X_1, X_2, \dots, X_n]$
 - Cada arista $X_i \rightarrow X_j$ en el DAG representa una **dependencia directa** entre las variables, donde X_i se llama **padre** de X_j (X_j es **hijo** de X_i)
 - Cada nodo X_i tiene asociado una distribución de probabilidad condicional $\mathbf{P}(X_i \mid \text{Parents}(X_i))$ que cuantifica el efecto de los padres en el nodo. Cuando las variables son discretas tales distribuciones corresponden a **tablas de probabilidad condicional** (CPTs)

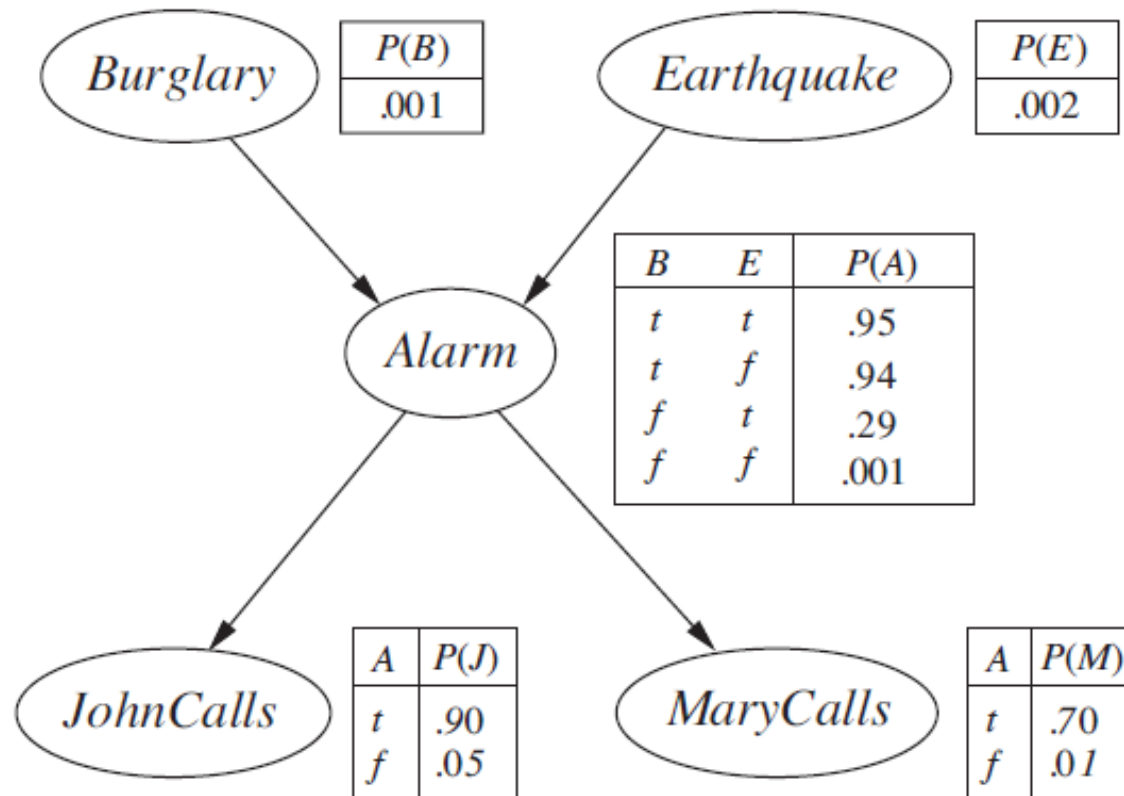
Redes Bayesianas

Ejemplo:

- “Tienes una alarma en casa que es confiable detectando intrusos, pero también puede activarse con temblores. Tienes dos vecinos: John y Mary que han prometido llamarte cuando escuchen la alarma. John confunde a veces la alarma con el timbre del teléfono. Mary le gusta escuchar música en alto volumen y a veces no escucha la alarma. ¿Cómo representamos este conocimiento en una RB)?”
- **Variables:** Robo (*Burglary*), Temblor (*Earthquake*), Alarma (*Alarm*), LlamadaJohn (*JohnCalls*), LlamadaMary (*MaryCalls*)
- Se tiene cierto conocimiento causal para construir la topología de la RB:
 - ▣ Un robo puede activar la alarma
 - ▣ Un temblor puede activar la alarma
 - ▣ La alarma provoca que Mary llame
 - ▣ La alarma provoca que John llame

Redes Bayesianas

Ejemplo:



Redes Bayesianas

- Las probabilidades resumen un conjunto potencialmente infinito de circunstancias:
 - ▣ María no oyó la alarma porque estaba escuchando música
 - ▣ John llama cuando timbra el teléfono
 - ▣ Un ratón activó la alarma
 - ▣ John y Mary no están en casa, etc.
- Es difícil lidiar con todas las situaciones por causa de: **laxitud e ignorancia!**

Redes Bayesianas

Tablas de probabilidad condicional (CPT):

- Cada fila de un CPT contiene la distribución de probabilidades para una combinación de valores de las variables condicionantes (padres del nodo).
- Si el nodo es booleano, cada fila de su CPT será un número p relativo a la probabilidad de $X_i = \text{true}$. La probabilidad de $X_i = \text{false}$ **no se indica**, ya que se puede calcular como $1-p$
- El CPT de un nodo sin padres es solo una fila con probabilidades “a priori”
- Un CPT de una variable booleana con k padres posee 2^k probabilidades
- Si una RB posee n nodos booleanos con k padres como máximo, para especificar la red completamente se necesita $O(n 2^k)$ probabilidades (parámetros de la RB)
 - Esto es, **crece linealmente con n** (la especificación de la probabilidad conjunta total requeriría $O(2^n)$ valores)

Redes Bayesianas

Semántica de las RBs: dos formas de entenderlas

- **Semántica Global** (o numérica): Se entiende las RBs como una forma de representar la distribución de probabilidad conjunta de un conjunto de variables aleatorias
 - ▣ Indica como se puede construir una RB
- **Semántica Local** (o topológica): Se entiende las RBs como una forma de codificar una serie de aseveraciones de independencia condicional
 - ▣ Indica como se puede hacer inferencia en una RB

Redes Bayesianas

Semántica Global

- La RB define la distribución de probabilidad conjunta total como el **producto de distribuciones condicionales locales** de cada nodo:

Así, para n variables $[X_1, X_2, \dots, X_n]$, una RB permite calcular la prob. de cualquier conjunción $(X_1=x_1 \wedge \dots \wedge X_n=x_n)$ (denotado $P(x_1, \dots, x_n)$):

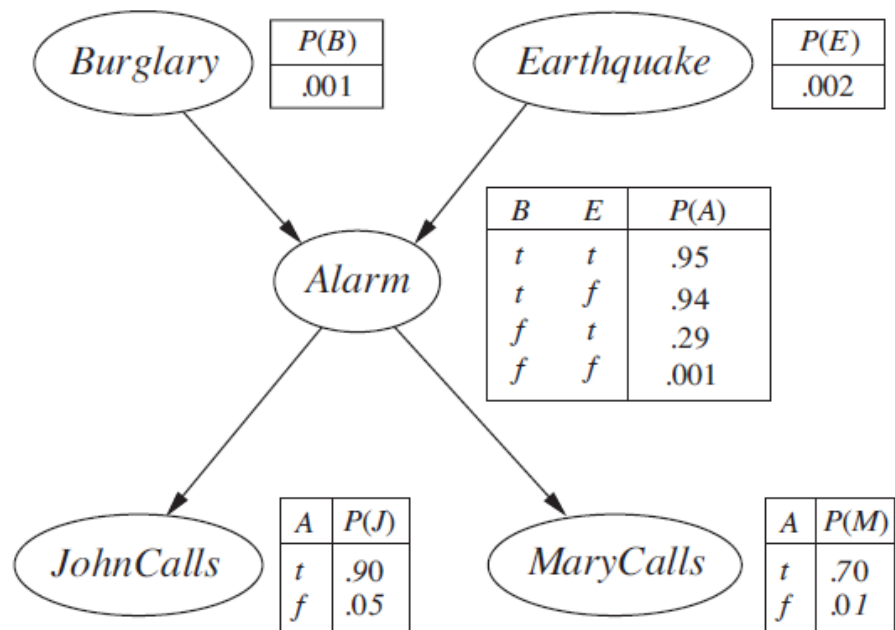
$$P(x_1, \dots, x_n) = \prod_{i=1 \dots n} P(x_i \mid \text{parents}(X_i))$$

donde $\text{parents}(X_i)$ denota los valores específicos de las variables padres de X_i , $\text{Parents}(X_i)$, que aparecen en la conjunción x_1, \dots, x_n

- Al ser una RB especificación de la distribución de probabilidad conjunta de una serie de variables, **esta puede ser usada para responder cualquier consulta acerca de las variables** efectuándose el productorio de las probabilidades cond. locales

Redes Bayesianas

Semántica Global: Ejemplo



Cuánto es $P(j, m, a, \neg b, \neg e)$?

$$= P(j \mid a) P(m \mid a) P(a \mid \neg b, \neg e) P(\neg b) P(\neg e)$$

$$= 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998$$

$$= 0.00063$$

Redes Bayesianas

Semántica Local (Topológica)

- La topología de una RB nos indica ciertas independencias condicionales:
 - Un nodo X_i es **condicionalmente independiente** (**CI**) de cualquier subconjunto Z de sus **no descendientes** (**ND**(X_i)) dados sus padres **Parents**(X_i):


$$X_i \perp Z \mid \text{Parents}(X_i), \quad Z \subset \text{ND}(X_i)$$

- Ausencia de arista entre dos nodos X_i, X_j indica que existe una independencia condicional entre ellos dado algún subconjunto Z de otras variables de la RB (puede ser vacío):

$$X_i \perp X_j \mid Z, \quad Z \subset U \setminus \{X_i, X_j\}$$

Redes Bayesianas


Semántica Local (Topológica): Ejemplo



- Independencias condicionales implicadas:
 - ▣ *Clima* es marginalmente independiente de cualquier otra(s) variable(s):
$$Clima \perp \mathbf{Z}, \quad \mathbf{Z} \subset \{Caries, DolorDiente, Sonda\}$$
 - ▣ $DolorDiente \perp Sonda \mid Caries$

Redes Bayesianas

Semántica Local (Topológica): Ejemplo




□ Independencias condicionales implicadas:

- $JohnCalls \perp Burglary \mid Alarm$; $MaryCalls \perp Burglary \mid Alarm$
- $JohnCalls \perp Earthquake \mid Alarm$; $MaryCalls \perp Earthquake \mid Alarm$
- $JohnCalls \perp MaryCalls \mid Alarm$; $Burglary \perp Earthquake$

Redes Bayesianas

Semántica Local (Topológica)


□ Interpretación gráfica de: $X \perp Z \subset \mathbf{ND}(X) \mid \mathbf{Parents}(X)$



Redes Bayesianas

Semántica Local (Topológica)

- **Manto de Markov** de un nodo X (**MB(X)**): Todos los padres, los hijos y los padres de los hijos (**esposos**) de X
- Un nodo X es condicionalmente independiente del resto de nodos de la RB dado el **MB(X)**: $X \perp Z \mid \mathbf{MB}(X)$, $Z \subset \mathbf{U} \setminus \{X \cup \mathbf{MB}(X)\}$
 - Toda la información para inferir acerca de X esta en su Manto de Markov



Redes Bayesianas

Construyendo una RB

1. Escoger un orden de las variables (**orden ancestral**): X_1, \dots, X_n
Una buena opción es colocar las variables causa precediendo sus efectos en el orden

2. Para $i = 1 \dots n$

- Del conjunto X_1, \dots, X_{i-1} escoger un conjunto mínimo de padres (**Parents**(X_i)) para X_i tal que se cumpla lo siguiente:

$$\mathbf{P}(X_i \mid X_1, \dots, X_{i-1}) = \mathbf{P}(X_i \mid \mathbf{Parents}(X_i))$$

Intuitivamente los padres deben ser aquellos que directamente influyen en X_i

- Para cada padre escogido colocar una arista hasta X_i

3. Escribir las tablas de probabilidades para cada nodo X_i :
 $\mathbf{P}(X_i \mid \mathbf{Parents}(X_i))$


Redes Bayesianas

Construyendo una RB

- El **orden ancestral correcto** es aquel donde las variables causas de raíz aparecen primero, luego las variables que ellas influncian y así sucesivamente hasta llegar a las variables hojas que no tienen influencia causal directa sobre las otras variables
- Qué pasa si no se escoge un orden ancestral correcta?


Redes Bayesianas

Construyendo una RB: Ejemplo asumiendo orden B, E, A, J, M



Redes Bayesianas

Construyendo una RB: Ejemplo asumiendo orden B, E, A, J, M




Redes Bayesianas

Construyendo una RB: Ejemplo asumiendo orden B, E, A, J, M

Burglary



Earthquake



$P(E \mid B) = P(E)$? **Si**

Redes Bayesianas

Construyendo una RB: Ejemplo asumiendo orden B, E, A, J, M





$P(E \mid B) = P(E)$? **Si**

$P(A \mid B, E) = P(A)$? **No,** $P(A \mid B) = P(A)$? **No,** $P(A \mid E) = P(A)$? **No,**

➡ B, E son padres de A

Redes Bayesianas

Construyendo una RB: Ejemplo asumiendo orden B, E, A, J, M



$P(E \mid B) = P(E)$? **Si**

$P(A \mid B, E) = P(A)$? **No**

$P(A \mid B) = P(A)$? **No,**

$P(A \mid E) = P(A)$? **No,**

➡ B, E son padres de A



$P(J \mid B, E, A) = P(J)$? **No,**

$P(J \mid B, E, A) = P(J \mid A)$? **SI**

➡ A es padre de J

Redes Bayesianas

Construyendo una RB: Ejemplo asumiendo orden B, E, A, J, M



$$P(E \mid B) = P(E)? \text{ Si}$$

$$P(A \mid B, E) = P(A)? \text{ No} \quad P(A \mid B) = P(A)? \text{ No}, \quad P(A \mid E) = P(A)? \text{ No},$$

➡ B, E son padres de A

$$P(J \mid B, E, A) = P(J)? \text{ No}, \quad P(J \mid B, E, A) = P(J \mid A)? \text{ SI}$$


➡ A es padre de J

$$P(M \mid B, E, A, J) = P(M)? \text{ No}, \quad P(M \mid B, E, A, J) = P(M \mid A)? \text{ SI}$$

➡ M es padre de J

Redes Bayesianas

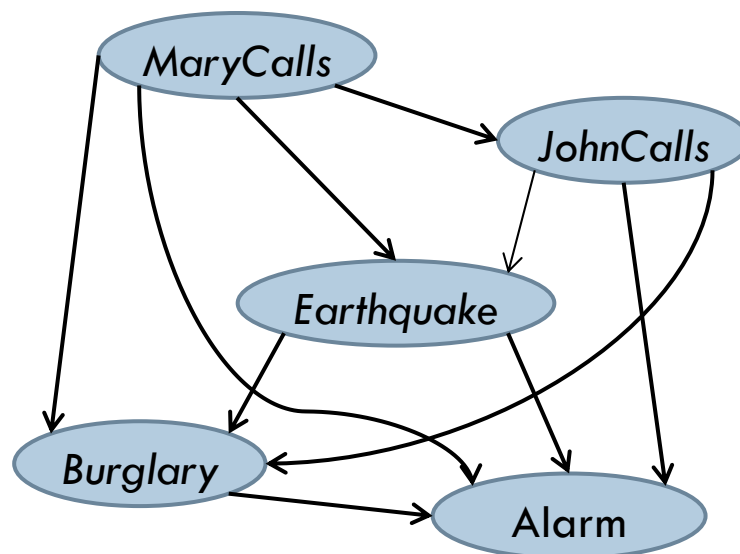
Construyendo una RB: Ejemplo asumiendo orden M, J, A, B, E



- La RB resultante tendrá dos aristas mas que la red original y requerirá mas parámetros (probabilidades condicionales) para ser especificada
- Algunas aristas pueden representar **relaciones tenues** que implican probabilidades difíciles o antinaturales de determinar
 - ▣ Ej. $P(\text{Earthquake} \mid \text{Alarm}, \text{Burglary})$
- En general es preferible tratar de construir la RB de causas para efectos (**modelo causal**) y no al contrario (**modelo de diagnóstico**)

Redes Bayesianas

Construyendo una RB: Ejemplo asumiendo orden M, J, E, B, A



- El orden M, J, E, B, A no es recomendable, ya que genera una RB con 9 aristas (5 mas que la RB original) y requerirá especificar 31 probabilidades distintas, lo mismo que se necesita para especificar la distribución de probabilidad conjunta
- Sin embargo, las tres RB codifican la misma distribución de prob. conjunta, solo que las dos ultimas no representan todas las independencias condicionales que existen

Inferencia en Redes Bayesianas

- **Inferencia** en una red bayesiana es la tarea de calcular la distribución de probabilidad posterior de una **variable de consulta** dados los valores de un conjunto de variables (**evidencia**)

$$P(X | E = e)$$

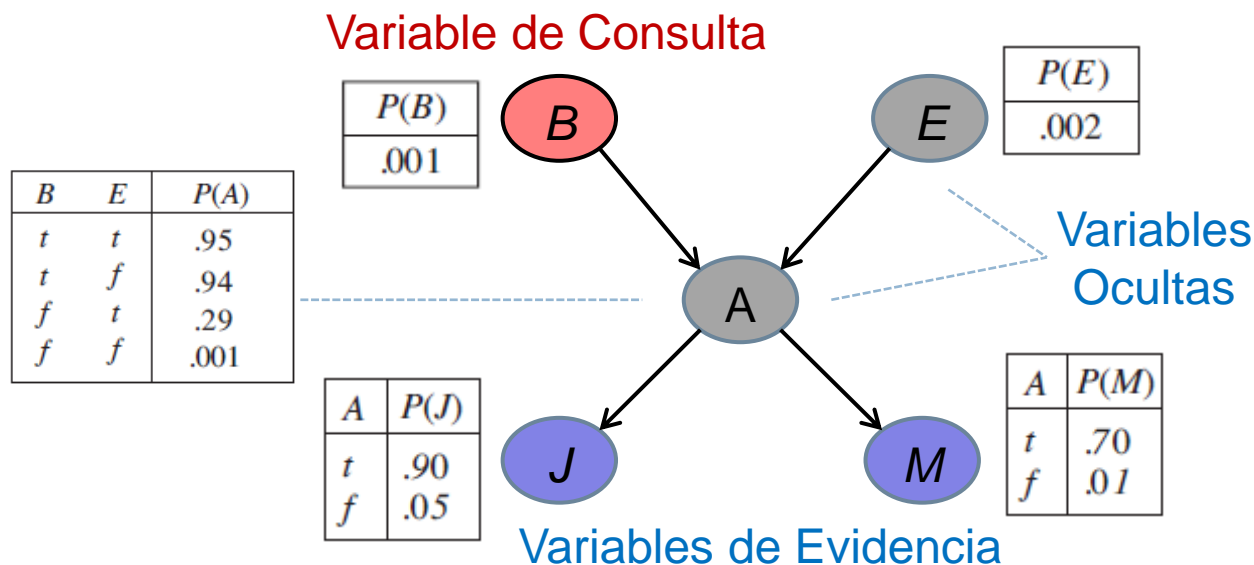
Notación

- X : variable de consulta
- E : variables de evidencia
- e : evidencia (atribución particular de las variables E)
- Y : variables no evidenciadas (ocultas)

El universo de variables de la RB es $\mathbf{X} = \{X\} \cup E \cup Y$

Inferencia en Redes Bayesianas

Ejemplo:

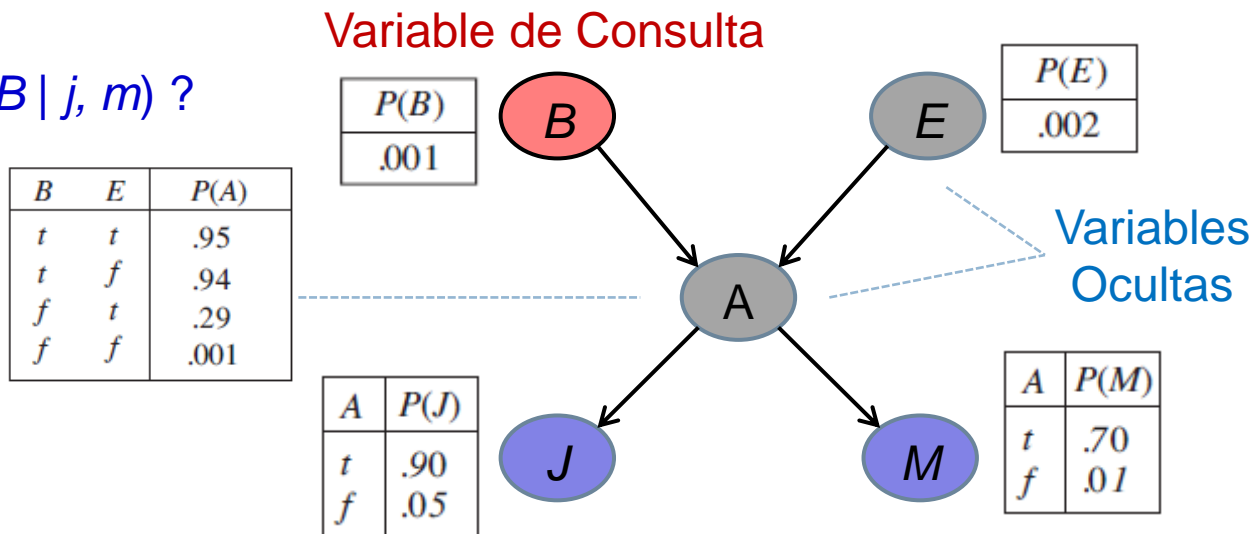


Se quiere encontrar $P(B | j, m)$?

- variable de consulta = B
- variables de evidencia = $\{J, M\}$
- evidencia = $\{j, m\}$
- variables ocultas = $\{E, A\}$

Inferencia en Redes Bayesianas

Ejemplo: $P(B | j, m)$?



De forma general: $P(X | \mathbf{e}) = \alpha P(X, \mathbf{e}) = \alpha \sum_{\mathbf{y}} P(X, \mathbf{e}, \mathbf{y})$

En el ejemplo: $P(B | j, m) = \alpha \sum_e \sum_a P(B, j, m, e, a)$

Para $B=b$: $P(b | j, m) = \alpha \sum_e \sum_a P(b) P(e) P(a | b, e) P(j | a) P(m | a)$

Reescribiendo: $P(b | j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a | b, e) P(j | a) P(m | a)$

$P(b | j, m) = 0.0005922 \alpha$; $P(\neg b | j, m) = 0.00149 \alpha$; $P(B | j, m) = [0.28, 0.72]$

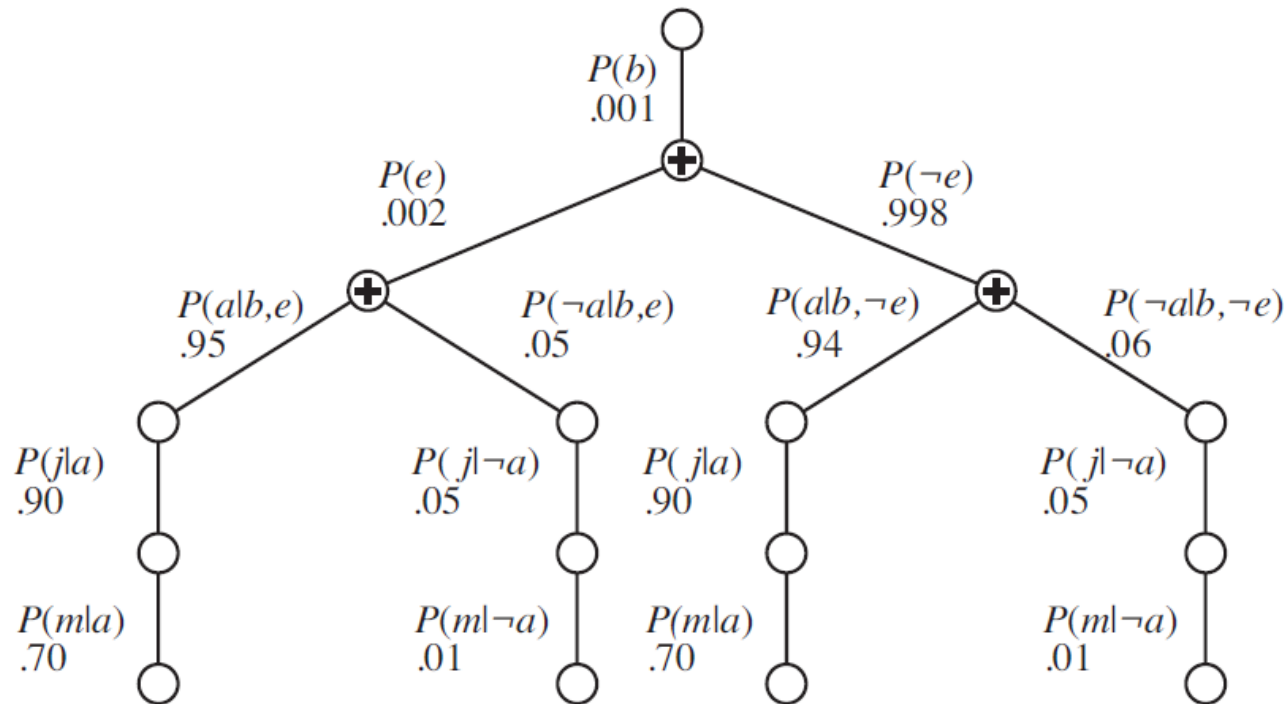
Usando la
semantica de
la RB

Inferencia en Redes Bayesianas

Inferencia por Enumeración

- Evalúa en profundidad el árbol de expresión

$$P(b \mid j, m) = \alpha P(b) \sum_e P(e) \sum_a P(a \mid b, e) P(j \mid a) P(m \mid a)$$



- Complejidad espacial es lineal en el numero de variables, pero la **complejidad de tiempo es exponencial**. Para n variables booleanas $O(2^n)$. Hay cálculos repetidos, Ej. $P(j \mid a) P(m \mid a)$

Inferencia en Redes Bayesianas

Algoritmo de Eliminación de Variables

- Elimina cálculos repetidos de la inferencia por enumeración
- **Idea**: hacer cálculos solo una vez y guardar los resultados
- Se convierte el problema en operaciones con **factores**.

Ej. RB Alarm:

$$P(B | j, m) = \alpha \underbrace{P(B)}_{f_1(B)} \sum_e \underbrace{P(e)}_{f_2(E)} \sum_a \underbrace{P(a | B, e)}_{f_3(A, B, E)} \underbrace{P(j | a)}_{f_4(A)} \underbrace{P(m | a)}_{f_5(A)}$$

- **Factor** es una matriz definida en un conjunto de variables (no evidenciadas) que se indexa con sus valores. **Ejemplos**:

$$f_4(A) = \begin{array}{|c|} \hline 0.9 \\ \hline 0.05 \\ \hline \end{array} \begin{array}{l} P(j | a) \\ P(j | \neg a) \end{array}$$

$$f_5(A) = \begin{array}{|c|} \hline 0.7 \\ \hline 0.01 \\ \hline \end{array} \begin{array}{l} P(m | a) \\ P(m | \neg a) \end{array}$$

Em términos de factores:

$$P(B | j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

Inferencia en Redes Bayesianas

Algoritmo de Eliminación de Variables

□ Operaciones con factores

- **Producto** (*pointwise product*): El producto de dos factores f_1 y f_2 genera un nuevo factor f cuyas variables son la unión de las variables y cuyos elementos son los productos de los elementos correspondientes

A	B	$f_1(A, B)$	\times	B	C	$f_2(B, C)$	$=$	A	B	C	$f_3(A, B, C)$
T	T	.3		T	T	.2		T	T	T	$.3 \times .2 = .06$
T	F	.7		T	F	.8		T	T	F	$.3 \times .8 = .24$
F	T	.9		F	T	.6		T	F	T	$.7 \times .6 = .42$
F	F	.1		F	F	.4		T	F	F	$.7 \times .4 = .28$
								F	T	T	$.9 \times .2 = .18$
								F	T	F	$.9 \times .8 = .72$
								F	F	T	$.1 \times .6 = .06$
								F	F	F	$.1 \times .4 = .04$


Inferencia en Redes Bayesianas

Algoritmo de Eliminación de Variables

Operaciones con factores

- **Suming out una variable:** Esta operación se realiza sumando las submatrices formadas de fijar la variable en cada uno de sus valores Ej.

$$\sum_a \mathbf{f}_3(A, B, C) = \mathbf{f}_3(a, B, C) + \mathbf{f}_3(\neg a, B, C) = \mathbf{f}(B, C)$$



<i>B</i>	<i>C</i>	$\mathbf{f}_3(A, B, C)$
T	T	.06
T	F	.24
F	T	.42
F	F	.28

+

<i>B</i>	<i>C</i>	$\mathbf{f}_3(A, B, C)$
T	T	.18
T	F	.72
F	T	.06
F	F	.04

=

<i>B</i>	<i>C</i>	$\mathbf{f}_3(A, B, C)$
T	T	.24
T	F	.96
F	T	.48
F	F	.32

Inferencia en Redes Bayesianas

Algoritmo de Eliminación de Variables

- Factores que no dependen de la variable que se esta sumando dentro del sumatorio puede ser movidos fuera. Por ejemplo

$$\sum_e f_2(E) \times f_3(A, B, E) \times f_4(A) \times f_5(A) = f_4(A) \times f_5(A) \times \sum_e f_2(E) \times f_3(A, B, E)$$

- Cualquier orden de eliminación de variables puede dar resultados válidos. Sin embargo, se pueden generar diferentes factores. El tamaño del mayor factor domina la complejidad de tiempo y espacio
- Encontrar una orden de eliminación optima es NP Completo. Una heurística importante es: considerar solamente en el proceso de eliminación las variables que son ancestros de la variable consulta y evidencia (las demás son irrelevantes).

Inferencia en Redes Bayesianas

Algoritmo de Eliminación de Variables: Ejemplo

$$\mathbf{P}(B \mid j, m) = \alpha \underbrace{\mathbf{P}(B)}_{\mathbf{f}_1(B)} \sum_e \underbrace{P(e)}_{\mathbf{f}_2(E)} \underbrace{\sum_a \underbrace{\mathbf{P}(a \mid B, e)}_{\mathbf{f}_3(A, B, E)} \underbrace{P(j \mid a)}_{\mathbf{f}_4(A)} \underbrace{P(m \mid a)}_{\mathbf{f}_5(A)}}_{\mathbf{f}_6(B, E)}$$
$$\mathbf{f}_6(B, E) = \sum_a \mathbf{f}_3(A, B, E) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A)$$
$$= (\mathbf{f}_3(a, B, E) \times \mathbf{f}_4(a) \times \mathbf{f}_5(a)) + (\mathbf{f}_3(\neg a, B, E) \times \mathbf{f}_4(\neg a) \times \mathbf{f}_5(\neg a))$$

$$\mathbf{P}(B \mid j, m) = \alpha \mathbf{f}_1(B) \times \underbrace{\sum_e \mathbf{f}_2(E) \times \mathbf{f}_6(B, E)}_{\mathbf{f}_7(B)}$$
$$\mathbf{f}_7(B) = \sum_e \mathbf{f}_2(E) \times \mathbf{f}_6(B, E)$$
$$= \mathbf{f}_2(e) \times \mathbf{f}_6(B, e) + \mathbf{f}_2(\neg e) \times \mathbf{f}_6(B, \neg e)$$

$$\mathbf{P}(B \mid j, m) = \alpha \mathbf{f}_1(B) \times \mathbf{f}_7(B)$$

Inferencia en Redes Bayesianas

Algoritmo de Eliminación de Variables

```
function ELIMINATION-ASK( $X, \mathbf{e}, bn$ ) returns a distribution over  $X$   
  inputs:  $X$ , the query variable  
            $\mathbf{e}$ , observed values for variables  $\mathbf{E}$   
            $bn$ , a Bayesian network specifying joint distribution  $\mathbf{P}(X_1, \dots, X_n)$   
  
   $factors \leftarrow []$   
  for each  $var$  in ORDER( $bn.VARS$ ) do  
     $factors \leftarrow [MAKE-FACTOR(var, \mathbf{e}) | factors]$   
    if  $var$  is a hidden variable then  $factors \leftarrow SUM-OUT(var, factors)$   
  return NORMALIZE(POINTWISE-PRODUCT( $factors$ ))
```

Librerías de Redes Bayesianas

- Pgmpy: <http://pgmpy.org/> (recomendado)
- Libpgm: <https://pythonhosted.org/libpgm/>
- <http://www.bayespy.org> (solo inferencia)
- Bnlearn (muy completa, en R)



Preguntas?